어떤 품목이, 어떤 매장에서,
얼마나 팔릴지 미리 압니다.

AI 기반 매출·수요 예측 — 폐기 감소, 위험 매장 탐지, 채널 최적화

98%	284개	품목별
매출 예측 정확도	매장 동시 예측	카테고리 단위 수요 예측

한양대학교 경영대학
빅데이터마케팅 랩 · 임보람 교수
brlim@hanyang.ac.kr
bigdatamarketinglab.com

1. AI 매출 예측으로 할 수 있는 것

매장별 매출 데이터가 있으면, AI는 단순히 “내일 매출이 얼마인지” 맞추는 것을 넘어서 **운영 전반의 의사결정**을 바꿀 수 있습니다.

	할 수 있는 것	왜 중요한가
1	**품목별 수요 예측**	유제품, 신선식품, 베이커리 등 카테고리별로 수요를 예측합니다. 수요를 알면 발주량이 정밀해지고, **식품 폐기가 줄어듭니다.**
2	**매장 위험 조기 탐지**	매출이 서서히 떨어지는 매장을 **수개월 전에** 감지합니다. 특정 품목의 판매량이 줄기 시작하면 그것이 전체 매출 하락의 선행 신호입니다.
3	**원인 분석**	매출이 떨어졌을 때, 그것이 경쟁사 때문인지, 고객 변화인지, 계절 요인인지를 **AI가 분리해서 알려줍니다.**
4	**채널별 맞춤 전략**	온라인 고객과 오프라인 고객은 의사결정 방식이 다릅니다. 채널별로 어떤 수준의 품목 관리가 효과적인지를 데이터로 보여줍니다.

2. 품목별 수요 예측 → 폐기율 감소

리테일에서 가장 큰 비용 손실 중 하나는 **식품 폐기**입니다. 유제품, 신선식품, 베이커리는 유통기한이 짧아서, 수요 예측이 틀리면 그대로 버려집니다.

AI가 카테고리별 수요를 예측하면, **발주량을 수요에 맞출 수 있습니다.**

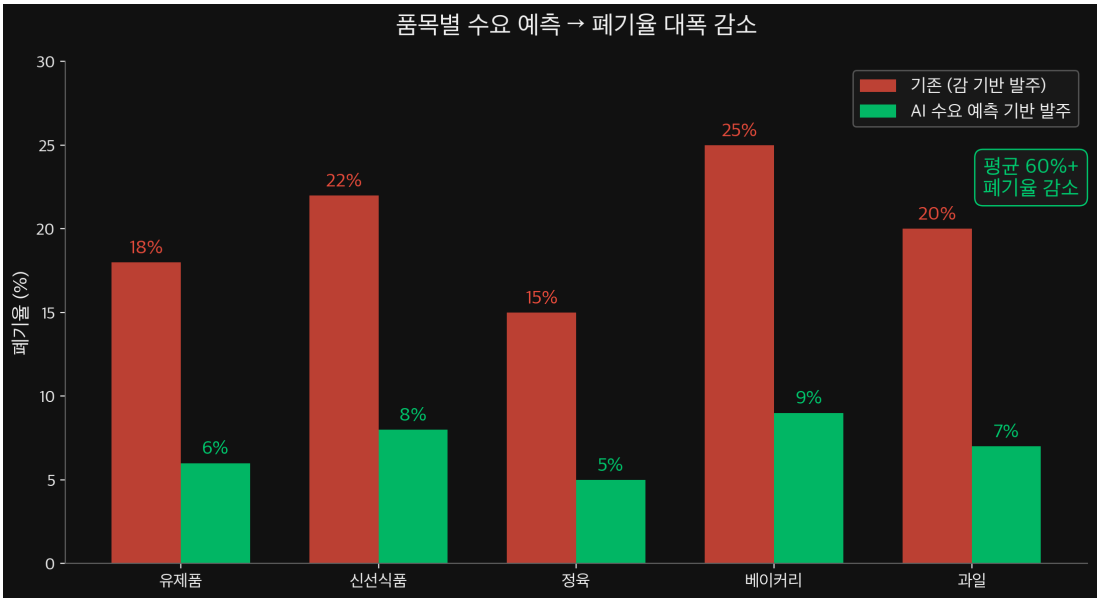

Figure 1: 품목별 수요 예측 기반 발주 시 예상 폐기율 감소 (개념도)

> **핵심:** 카테고리별로 "다음 주에 이 매장에서 유제품이 얼마나 팔릴지"를 알면, 발주 단위가 바뀝니다. 과잉 발주로 인한 폐기, 과소 발주로 인한 기회 손실 — 양쪽 모두 줄어듭니다.

실제로 284개 슈퍼마켓 매장 데이터를 분석한 결과, AI 모델은 **카테고리 수준의 구매 패턴**을 정밀하게 학습합니다. 고객이 어떤 카테고리 상품을 몇 가지 샀는지, 장바구니 구성이 어떤지가 매출을 결정하는 가장 강력한 변수였습니다.

3. 매장 위험 조기 탐지

매출이 떨어지는 매장을 **실적이 나빠진 다음에** 발견하면 이미 늦습니다.
AI 예측 모델은 매장별 매출 추이를 지속적으로 모니터링하면서, **하락 추세가 시작되는 시점**을 탐지합니다.

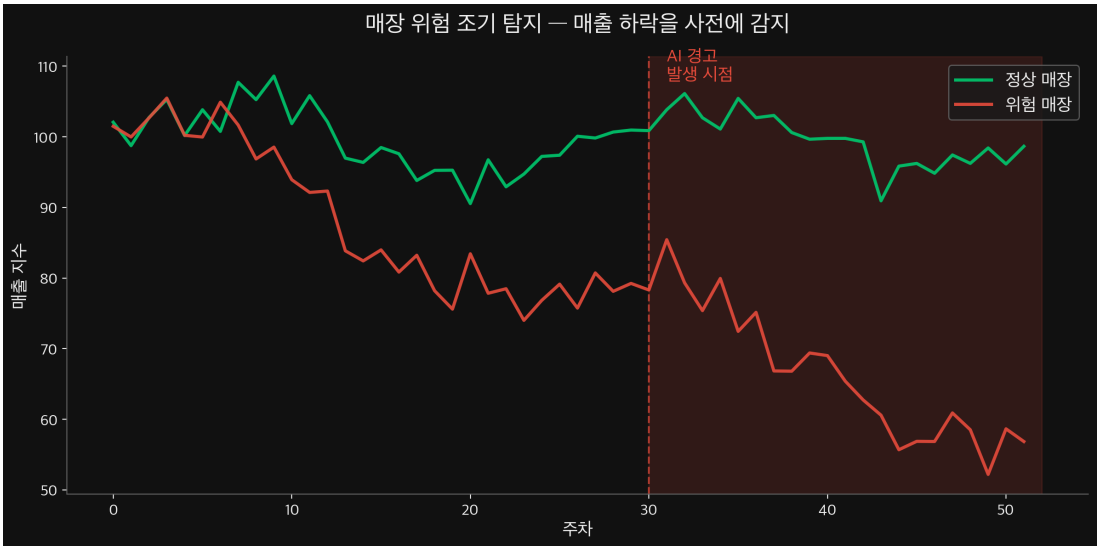

Figure 2: 정상 매장 vs 위험 매장 — 하락 추세를 조기에 감지

3.1 어떤 신호를 보는가

- **특정 품목의 판매량 감소가 먼저 나타난다** — 전체 매출이 떨어지기 전에, 특정 카테고리(예: 신선식품)의 판매가 먼저 줄어드는 패턴
- **고객 수 변화** — 방문 고객 수의 감소는 매출 하락의 가장 강력한 선행 지표
- **장바구니 구성 변화** — 고객이 사는 품목의 다양성이 줄어들면 매장 이탈의 신호

> **시사점:** 매출이 떨어진 후에 "왜 떨어졌지?"를 분석하는 대신, AI가 **수개월 전에** "이 매장 주의해야 합니다"라고 알려줍니다. 인력 재배치, 프로모션, 매장 리뉴얼 등의 **선제 대응**이 가능해집니다.

4. 왜 안 팔리는지까지 알려줍니다

매출이 떨어졌을 때, 가장 중요한 질문은 "왜?"입니다.

원인	AI가 보는 신호	대응
경쟁사 출점	반경 내 경쟁 매장 수 변화, 고객 이동 패턴	차별화 전략, 가격 대응
고객 이탈	방문 고객 수 감소, 단골 비율 하락	타겟 프로모션, 로열티 프로그램
구매 패턴 변화	장바구니 구성 변화, 특정 카테고리 감소	품목 재구성, MD 전략 수정
계절/시기 효과	시계열 패턴, 전년 동기 대비	시즌별 발주 조정
지역 인구 변화	상권 인구 추이, 연령대 변화	장기 전략 재검토

Table 1: 매출 변동 원인 분석 체계

AI 모델은 SHAP(Shapley Additive Explanations) 기법으로 **각 변수가 예측에 얼마나 기여했는지**를 정량적으로 분해합니다. "이 매장의 매출이 떨어진 이유의 60%는 고객 수 감소, 25%는 장바구니 축소, 15%는 계절 효과" — 이런 수준의 분석이 가능합니다.

5. 온라인과 오프라인은 다르게 관리해야 합니다

284개 매장 데이터를 분석한 결과, 가장 의외의 발견은 **온라인과 오프라인에서 매출을 결정하는 상품 분류 단위가 정반대**라는 것이었습니다.

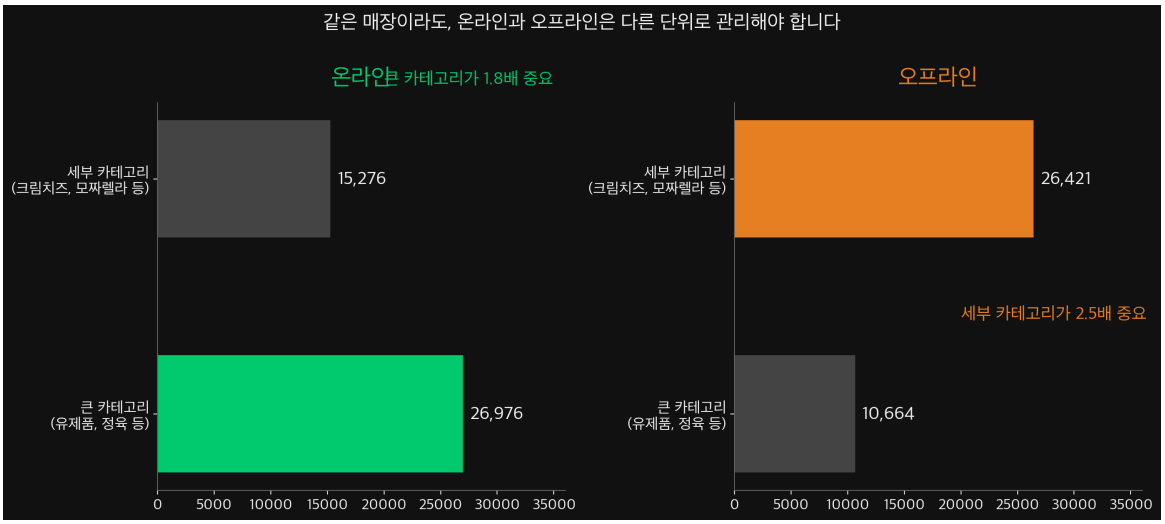

Figure 3: 온라인: 큰 카테고리 중심 / 오프라인: 세부 카테고리 중심

	온라인	오프라인
핵심 단위	큰 카테고리 (Class)	세부 카테고리 (Subclass)
고객 행동	"유제품 3종, 과일 2종"	"크림치즈 vs 모짜렐라"
쇼핑 방식	검색 → 필터 → 장바구니	보고 → 만지고 → 고르기
관리 원칙	**카테고리 구색 다양성**	**세부 상품 진열 큐레이션**

실무 원칙: 온라인 MD는 "카테고리를 얼마나 다양하게 제공하는가"를 기준으로, 오프라인 MD는 "어떤 세부 상품을 눈높이에 놓는가"를 기준으로 기획해야 합니다.

이 결과는 4가지 서로 다른 모델 사양에서 **100% 일관**되게 확인되었습니다.

6. 예측 정확도

284개 슈퍼마켓 매장의 실제 거래 데이터로 구축하고, **학습에 사용하지 않은 미래 기간의 데이터**로만 검증한 결과입니다.

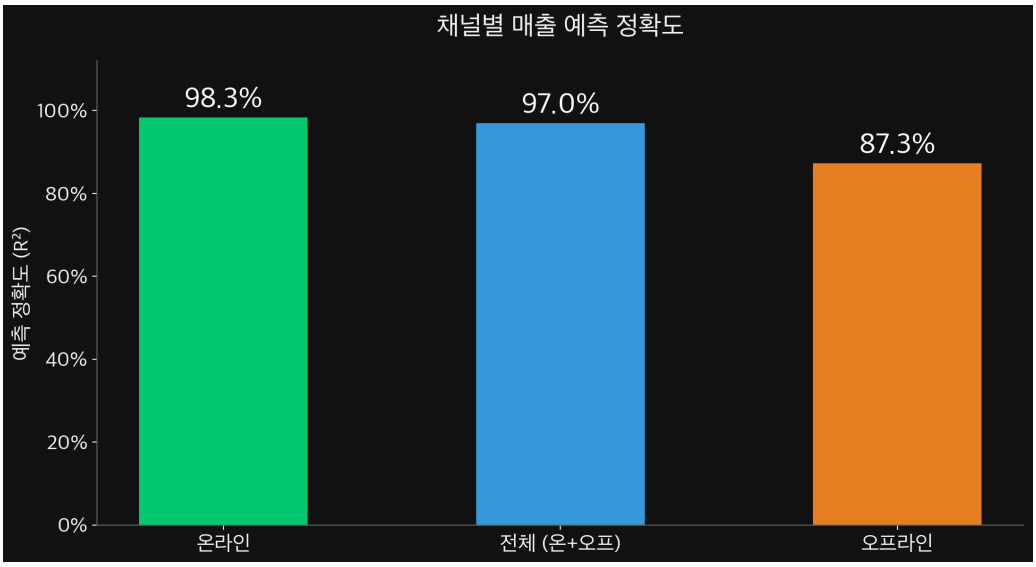

Figure 4: 채널별 매출 예측 정확도 (Out-of-sample, R^2)

	온라인	전체	오프라인
예측 정확도 (R^2)	**98.3%**	**97.0%**	87.3%
검증 건수	2,560건	3,185건	3,057건
분석 매장 수	225개	284개	281개

오프라인 매출은 충동 구매, 날씨, 매장 환경 등 변수가 많아 예측 난이도가 높지만, 그래도 87%의 설명력을 달성합니다. 데이터가 충분히 축적될수록 정확도는 더 올라갑니다.

분석 방법:

- XGBoost + LightGBM 앙상블 모델
- 149개 변수 (고객 구매 패턴, 상품 구성, 경쟁 환경, 시계열 추세 등)
- SHAP 기반 변수 중요도 해석 — “왜 이런 예측이 나왔는지”까지 설명

7. 한양대학교 빅데이터마케팅 랩

연구실	한양대학교 경영대학 빅데이터마케팅 랩 (BDM Lab)
교수	임보람 (Ph.D., UT Dallas / M.S., UT Austin)
전문 분야	AI/ML 기반 매출·수요 예측, 소비자 행동 분석, 인과분석
핵심 기술	XGBoost/LightGBM 앙상블, SHAP 해석, 시계열 예측
적용 업종	슈퍼마켓, 프랜차이즈, 리테일, 식음료

7.1 데이터만 있으면 됩니다

- **필요한 것:** 매장별 일간 또는 주간 매출 데이터 (최소 6개월)
- **추가 분석 가능:** 품목별 거래 데이터, 고객 정보 (로열티카드 등)
- **외부 데이터 구매 불필요** — 자사 POS 데이터만으로 고정밀 예측 가능

문의

임보람 교수
한양대학교 경영대학
빅데이터마케팅 랩

brlim@hanyang.ac.kr
bigdatamarketinglab.com